

PROJET 01

Analyse Statistique Complète Marchés Financiers

Dataset synthétique de 50 000 observations · 34 variables · 6 secteurs. Les 6 piliers statistiques indispensables avant tout projet Data Science.

Auteur	Aboubacar COMPO
Profil	Ingénieur Télécoms — Data Scientist en reconversion
Localisation	Dakar, Sénégal
Contact	abccompo90@gmail.com
Contexte	Challenge 100 jours ML — Projet 01/20 du portfolio
Date	Avril 2026

« La statistique est la grammaire de la Data Science. Avant tout modèle, il faut savoir décrire, questionner et comprendre les données. »

Sommaire

Partie	Contenu	Page
0	Contexte et dataset synthétique	3
1	Statistique univariée	4
2	Distributions de probabilité	5
3	Échantillonnage et biais	6
4	Statistique bivariée	7
5	Tests bivariés complets	8
6	Statistique multivariée — PCA	9
7	Synthèse, limites et extensions	10

Partie 0 — Contexte et dataset

Ce rapport présente une analyse statistique de bout en bout sur un dataset synthétique de marchés financiers. L'objectif est **pédagogique** : démontrer, sur données contrôlées, la méthodologie à appliquer avant tout projet de Data Science ou Machine Learning.

Le dataset comprend **50 000 observations** réparties sur **34 variables** : prix et rendements journaliers, indicateurs techniques (RSI, MACD, bandes de Bollinger), ratios fondamentaux (PER, PBR, ROE, ROA), métadonnées (secteur, bourse, pays, rating) et variables macro (taux, inflation, VIX).

Six secteurs sont couverts : **Tech, Finance, Énergie, Santé, Consommation, Industrie**. Des propriétés statistiques réalistes ont été injectées : distribution log-normale des prix, queues épaisses (Student-t) sur les rendements, corrélations sectorielles cohérentes.

Structure du dataset

Type	Variables	Exemples
Identifiants	5	ticker, secteur, bourse, pays, rating
Prix / rendements	6	prix_cloture, rendement_jour, volatilite_20j
Volumes / tailles	3	volume, market_cap_m, employes
Ratios fondamentaux	6	per, pbr, roe, roa, debt_equity, dividend_yield
Indicateurs techniques	5	rsi, macd, moy_mobile_50, moy_mobile_200, bollinger_width
Macro / marché	4	taux_central, inflation, vix, sentiment
Autres	5	anciennete, beta, default, recent_date, prix_ouverture

Pourquoi un dataset synthétique ? Contrôle total sur les propriétés statistiques injectées → on peut vérifier que notre pipeline détecte correctement les fat tails, les corrélations et les biais qu'on y a introduits. C'est la meilleure façon de valider une méthodologie avant de l'appliquer sur données réelles.

Partie 1 — Statistique univariée

L'analyse univariée examine chaque variable isolément pour identifier sa **tendance centrale**, sa **dispersion**, sa **forme** de distribution et ses éventuels **outliers**.

Résultats clés sur les variables financières

Variable	Moy.	Médiane	Écart-type	Asymétrie	Kurtosis
rendement_jour	0.0003	0.0003	0.020	-0.05	6.40
volatilite_20j	0.0225	0.0213	0.010	0.81	1.32
per	20.54	19.94	11.00	0.37	-0.31
volume	2.8M	1.2M	5.7M	10.17	210.4
beta	1.02	1.02	0.24	0.06	-0.40
rsi	50.19	50.20	17.82	0.00	-0.14

Enseignements : le **rendement_jour** a une kurtosis de 6.4 (très supérieure à 0 pour une Normale) → queues épaisses caractéristiques des rendements réels. Le **volume** est extrêmement asymétrique (skew = 10.2) : c'est une variable log-normale typique, qu'il faudrait transformer (log) avant modélisation.




Figure 1.1 — Distributions univariées des 6 variables clés. Les queues épaisses du rendement_jour sont visibles.

Détection d'outliers — comparatif

Variable	IQR (%)	Z-score (n)	MAD (n)
rendement_jour	2.61	481	96
volatilite_20j	1.87	420	42
per	0.39	122	0
beta	0.13	28	0
rsi	0.68	0	0

Piège classique : le Z-score suppose la normalité. Sur des rendements *fat-tailed*, il sur-estime ou sous-estime les outliers selon les cas. La méthode **MAD** (Median Absolute Deviation) est plus robuste et doit être privilégiée en finance.

Partie 2 — Distributions de probabilité

Quelle loi théorique modélise le mieux les rendements journaliers ? La Normale est souvent utilisée par défaut, mais est-elle adaptée ?

Tests de normalité sur le rendement journalier

Test	Statistique	p-value	H0 rejetée ($\alpha=5\%$)
Shapiro-Wilk	0.9832	≈ 0	OUI
Kolmogorov-Smirnov	0.0313	≈ 0	OUI
Jarque-Bera	85 420	≈ 0	OUI
Anderson-Darling	138 50	(> 0.787)	OUI

Avec 50 000 observations, tous les tests rejettent la normalité, même un écart microscopique devient significatif. C'est pourquoi il faut **toujours coupler les tests avec du visuel** (QQ-plot) et des métriques (kurtosis, skewness) pour juger de la gravité de l'écart.

Comparaison Normale vs Student-t (AIC)

Loi	Paramètres	AIC	BIC	Verdict
Normale	$\mu=0, \sigma=0.020$	-248 193	-248 175	modèle de base
Student-t	$df=6.14, scale=0.020$	-252 038	-252 011	meilleur ajustement





Figure 2.1 — QQ-plots. La Student-t (droite) ajuste bien mieux les queues que la Normale.

Stylized facts confirmés sur les rendements : kurtosis excess de 6.4 (fat tails), asymétrie proche de 0, faible autocorrélation des rendements bruts. Impact métier : la **VaR gaussienne sous-estime** le risque de perte extrême → préférer VaR historique ou Expected Shortfall.

Partie 3 — Échantillonnage et biais

Théorème Central Limite — vérification empirique

Taille n	σ observé des moyennes	σ théorique ($\sigma/\sqrt{n}$)	Rapport
5	0.008885	0.009044	0.98
30	0.003707	0.003692	1.00
100	0.002018	0.002022	1.00
500	0.000913	0.000904	1.01



TCL validé : même sur une population fat-tailed (rendements), la distribution des moyennes converge vers une Normale, et son écart-type suit exactement $\sigma/\sqrt{n}$. **Conséquence pratique** : on peut utiliser des IC gaussiens sur des moyennes même si la population originale ne l'est pas — à condition d'avoir assez d'observations.

Bootstrap : IC 95 % du rendement moyen

Moyenne observée	IC inf (2.5%)	IC sup (97.5%)	SE bootstrap
0.000255	0.000087	0.000432	0.000088

Biais de sélection et de survie

Le biais de survie apparaît quand on exclut les actifs en défaut (ou les entreprises disparues) : la performance moyenne des 'survivants' surestime celle de la population complète. Dans notre dataset, l'écart est faible (−0.02 %) car les défauts représentent 2 % seulement — mais sur données réelles, ce biais peut gonfler artificiellement les rendements de 1 à 3 % par an.

Autres biais silencieux en finance : look-ahead bias (utiliser des données futures), survivorship bias, selection bias (index actuel $\neq$ index historique). Toujours documenter les filtres appliqués au dataset et leurs implications.

Partie 4 — Statistique bivariée

L'analyse bivariée identifie les **relations entre paires de variables** : corrélations, régressions simples, tests d'indépendance.




Figure 4.1 — Heatmap de corrélation : Pearson (gauche) vs Spearman (droite).

Top 5 corrélations les plus fortes

Variable 1	Variable 2	Corrélation (Pearson)
volatilité_20j	beta	0.333
sentiment	vix	0.024
volatilité_20j	vix	0.012
beta	rsi	0.011
beta	roe	0.009

La seule corrélation notable : **volatilité ↔ bêta** ($p = 0.33$). C'est attendu : par définition du bêta, un actif à $\beta=1.5$ amplifie de 1.5x les mouvements du marché, donc sa volatilité absolue augmente mécaniquement.

Régression linéaire : VIX → Volatilité 20j

Coefficient	Valeur
Intercept	0.0222
Pente	0.00002
R²	0.00014
RMSE	0.00988
p-value	0.009
n	50 000

Le R^2 très faible (0.014 %) montre que la relation VIX→volatilité, bien que statistiquement significative ($p < 0.05$), est **pratiquement inexploitable en prédiction**. Ceci illustre un piège classique : avec $n=50\,000$, **tout devient significatif**. Il faut toujours mesurer la force effective de la relation, pas seulement sa p-value.

Partie 5 — Tests bivariés complets

Dans cette partie, nous vérifions si des **différences observées** entre groupes sont statistiquement significatives **ET** pratiquement importantes (tailles d'effet).

t-test Welch : PER Tech vs PER Santé

Métrique	Valeur
Moyenne PER Tech	20.56
Moyenne PER Santé	20.64
Différence	-0.08
Statistique t	-0.46
p-value	0.648
Cohen's d	-0.007
Conclusion	H0 non rejetée

ANOVA + Kruskal-Wallis : PER par secteur (6 groupes)

Test	Statistique	p-value	Taille d'effet	Conclusion
ANOVA one-way	F = 0.39	0.856	eta² = 0.00004	H0 non rejetée
Kruskal-Wallis	H = 1.09	0.955	—	H0 non rejetée




Figure 5.1 — Boxplots du PER par secteur. Distributions très similaires.

Chi² d'indépendance : Secteur × Bourse

Statistique	Valeur
χ^2	36.34
Degrés de liberté	20
p-value	0.014

V de Cramer	0.0135
Intensité	négligeable
Conclusion	H0 rejetée (mais V négligeable)

Leçon clé de la Partie 5 : la p-value de 0.014 sur le χ^2 indique un lien statistique entre secteur et bourse — mais le V de Cramer de 0.013 révèle qu'il est **négligeable en pratique**. À grande échelle, **toujours rapporter la taille d'effet** (Cohen's d, η^2 , Cramer's V) aux côtés de la p-value.

Partie 6 — Analyse en composantes principales

La PCA réduit un espace à **p variables corrélées** à un espace à **k composantes orthogonales**, ordonnées par variance expliquée. C'est le socle de nombreuses techniques : détection d'anomalies, visualisation, pré-traitement pour ML.

Variance expliquée par composante (top 8)

Composante	Variance (%)	Variance cumulée (%)
PC1	8.89	8.89
PC2	6.89	15.79
PC3	6.80	22.58
PC4	6.77	29.35
PC5	6.73	36.09
PC6	6.70	42.79
PC7	6.70	49.49
PC8	6.68	56.16




Figure 6.1 — Scree plot et variance cumulée.

Interprétation des axes (loadings > 0.5)

Axe	Variables dominantes	Interprétation métier
PC1	volatilite_20j (0.82), beta (0.82)	Risque de marché
PC2	vix (0.59), sentiment (0.55)	Sentiment macro
PC3	pbr (0.49), per (0.42), market_cap (0.40)	Valorisation
PC4	rsi (0.47), roa (0.44), macd (0.36)	Momentum / rentabilité




Figure 6.2 — Cercle des corrélations sur PC1 × PC2.

Lecture : PC1 est un axe de **risque** (volatilité et bêta pointent vers la droite), PC2 un axe de **sentiment** (VIX et sentiment vers le haut). Projection d'un nouvel actif sur ces 2 axes = carte d'identité risque/sentiment. La variance expliquée relativement faible par PC1 (9 %) est due à la construction du dataset synthétique, qui minimise volontairement les corrélations entre ratios pour bien illustrer la méthodologie.

Synthèse, limites et extensions

Ce que le projet démontre

Compétence	Démonstration
Statistique descriptive rigoureuse	Mesures CV, MAD, kurtosis + interprétation
Maîtrise des tests statistiques	Paramétriques et non-paramétriques, tailles d'effet
Conscience des biais	Survie, sélection, look-ahead
Réduction de dimensionnalité	PCA + interprétation économique des axes
Code modulaire	Modules src/ réutilisables
Reproductibilité	Seeds fixés, notebook exécuté de bout en bout

Limites reconnues

- 1. Dataset synthétique.** Les propriétés statistiques sont contrôlées mais simplifiées. Sur données réelles : non-stationnarité, régimes de marché, autocorrélations à plusieurs horizons.
- 2. Pas d'analyse temporelle.** Les rendements sont traités en coupe transversale. Une extension naturelle : stationnarité (ADF, KPSS), autocorrélation (ACF/PACF), modèles GARCH.
- 3. Pas de test d'hypothèse multivarié.** MANOVA, Hotelling's T^2 , copules pourraient compléter.

Extensions prévues

Ce projet est la fondation méthodologique du portfolio. Les projets suivants s'appuient dessus :

Projet	Thème
02	Détection de fraude Mobile Money (en cours)
03	Scoring crédit individus non bancarisés (lien TRANSPA GUINEE)
04	Séries temporelles — stationnarité et GARCH sur rendements
05	Clustering non supervisé — profils d'investisseurs
...	20 projets au total sur le Challenge 100 jours ML

Merci d'avoir lu ce rapport. Le code complet, le notebook exécutable et l'artefact HTML interactif sont disponibles sur GitHub. Feedback et discussions bienvenus sur LinkedIn.

Aboubacar COMPO — abccompo90@gmail.com — Dakar, avril 2026